

「社内資料」とか「社外秘」とかそういうやつ

数式を中心に復習する

<div style="page-break-after: always;"> </div>

固有方程式

$$\det(\lambda I - A) = 0$$

各要素の意味

- \det は行列式(determinant) を意味する。
- λ は固有値
- I は
- A は

<div style="page-break-after: always;"> </div>

特異値分解

$$A = U\Sigma V^T$$

各要素の意味

- A は
- U は
- Σ は
- V^T は
-

<div style="page-break-after: always;"> </div>

ベルヌーイ分布

$$Ef(x; p) = p^x(1 - p)^{1-x}$$

各要素の意味

- x は
- p は
- $f(x; p)$ は
- $p^x(1 - p)^{1-x}$ は

<div style="page-break-after: always;"> </div>

ベルヌーイ分布の期待値

$$\begin{aligned}\mathbb{E}[X] &= \sum_{x=0}^1 x p^x (1-p)^{1-x} \\ &= p\end{aligned}$$

各要素の意味

<div style="page-break-after: always;"> </div>

ベルヌーイ分布の分散

$$\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

$$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

$$= \sum_{x=0}^1 x^2 p^x (1-p)^{1-x} - p^2$$

$$= p - p^2$$

$$= p(1-p)$$

各要素の意味

<div style="page-break-after: always;"> </div>

マルチヌーイ分布（カテゴリ分布）

$$f(x; p) = \prod_{j=1}^k p_j^{x_j} \quad (\text{ただし、} \sum_{j=1}^k p_j = 1, \ 0 \leq p_j \leq 1, \ j = 1, \dots)$$

各要素の意味

<div style="page-break-after: always;"> </div>

マルチヌーイ分布（カテゴリ分布）の負の対数尤度

$$\begin{aligned} -\log L_D(p) &= -\log \prod_{i=1}^n f(x_i; p) \\ &= -\sum_{i=1}^n \log \prod_{j=1}^k p_j^{x_{ij}} \\ &= -\sum_{i=1}^n \sum_{j=1}^k \log p_j^{x_{ij}} \\ &= -\sum_{i=1}^n \sum_{j=1}^k x_{ij} \log p_j \end{aligned}$$

正規分布

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2\sigma^2} (x - \mu)^2 \right)$$

各要素の意味

<div style="page-break-after: always;"> </div>

正規分布の負の対数尤度

$$L(\mu) = \prod_{i=1}^n f(x_i; \mu)$$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} (x_i - \mu)^2 \right)$$

$$-\log L(\mu) = -\log \left(\prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} (x_i - \mu)^2 \right) \right)$$

$$= -\sum_{i=1}^n \log \left(\frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} (x_i - \mu)^2 \right) \right)$$

$$= -\sum_{i=1}^n \left(\log \left(\frac{1}{\sqrt{2\pi}} \right) - \frac{1}{2} (x_i - \mu)^2 \right)$$

$$= -n \log \left(\frac{1}{\sqrt{2\pi}} \right) - \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2$$

正規分布の最尤推定

$$\frac{d}{d\mu} g(\mu) = \frac{1}{2} \sum_{i=1}^n \frac{d}{d\mu} (x_i - \mu)^2$$

$$= \frac{1}{2} \sum_{i=1}^n (-2(x_i - \mu))$$

$$= \sum_{i=1}^n \mu - \sum_{i=1}^n x_i$$

$$= n\mu - \sum_{i=1}^n x_i$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

エントロピー

$$H(X) = - \sum_x p(x) \log_2 p(x)$$

各要素の意味

<div style="page-break-after: always;"> </div>

交差エントロピー(クロスエントロピー)の定義

$$H(p, q) = - \sum_x p(x) \log_2 q(x)$$

各要素の意味

- $p(x)$ 真の(正解の)確率分布
- $q(x)$ 推定したモデルの確率分布

<div style="page-break-after: always;"> </div>

二値交差エントロピー(バイナリクロスエントロピー) ※1/8 追加※

$$D_{BC} = -P(x=0) \log Q(x=0) - (1 - P(x=0)) \log(1 - Q(x=0))$$

各要素の意味

- $p(x)$ 真の(正解の)確率分布
- $q(x)$ 推定したモデルの確率分布

<div style="page-break-after: always;"> </div>

KLダイバージェンス

$$D(p||q) = \sum_x p(x) \log_2 \frac{p(x)}{q(x)}$$

各要素の意味

<div style="page-break-after: always;"> </div>

JSダイバージェンス

$$D_{JS}(p||q) = \frac{1}{2} \left(\sum_x p(x) \log_2 \frac{p(x)}{r(x)} + \sum_x q(x) \log_2 \frac{q(x)}{r(x)} \right)$$

$$r(x) = \frac{p(x) + q(x)}{2}$$

各要素の意味

<div style="page-break-after: always;"> </div>

ベイズの定理

$$p(C|x) = \frac{p(x|C)p(C)}{p(x)}$$

各要素の意味

<div style="page-break-after: always;"> </div>

バイアス・バリエアンス・ノイズ

$$\mathbb{E}(L) = \int \{y(x) - h(x)\}^2 p(x) dx + \iint \{h(x) - t\}^2 p(x, t) dx dt$$

$$\int \{\mathbb{E}_D[y(x; D)] - h(x)\}^2 p(x) dx$$

$$\int \mathbb{E}_D[\{y(x; D) - \mathbb{E}_D[y(x; D)]\}^2] p(x) dx$$

$$\iint \{h(x) - t\}^2 p(x, t) dx dt$$

各要素の意味

<div style="page-break-after: always;"> </div>

シグモイド関数

$$f(x) = \frac{1}{1 + \exp(-x)}$$

各要素の意味

- $\exp(-x)$ は e^{-x} の意、 $x=0$ の時1となるため、 $f(x) = \frac{1}{2}$ となる
-

<div style="page-break-after: always;"> </div>

ReLU

$$f(x) = \max(0, x)$$

各要素の意味

<div style="page-break-after: always;"> </div>

オッズ

$$\frac{p(y = 1|x)}{p(y = 0|x)} = \frac{\hat{y}}{1 - \hat{y}}$$

$$\begin{aligned}\frac{\hat{y}}{1 - \hat{y}} &= \frac{\frac{1}{1 + \exp(-w^T x - b)}}{1 - \frac{1}{1 + \exp(-w^T x - b)}} \\ &= \frac{1}{(1 + \exp(-w^T x - b)) - 1} \\ &= \frac{1}{\exp(-w^T x - b)} \\ &= \exp(w^T x - b)\end{aligned}$$

ガウスクアーネル

$$k(x, x') = \exp \left(-\frac{||x - x'||^2}{\beta} \right)$$

各要素の意味

<div style="page-break-after: always;"> </div>

正則化

$$E + \lambda_2 ||w||_2^2$$

$$E + \lambda_1 ||w||_1$$

$$E + \lambda_1 ||w||_1 + \lambda_2 ||w||_2^2$$

各要素の意味

<div style="page-break-after: always;"> </div>

ソフトマックス

$$\text{softmax}(z)_i = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$$

Numpy表記 : `np.exp(z) / np.sum(np.exp(z))`

各要素の意味

<div style="page-break-after: always;"> </div>

二乗和誤差

$$\frac{1}{2} \sum_{k=1}^K (y_k - t_k)^2$$

各要素の意味

<div style="page-break-after: always;"> </div>

生成モデル

$$p(y|x)p(x) = \frac{p(x, y)}{p(x)} \cdot p(x) = p(x, y)$$

各要素の意味

<div style="page-break-after: always;"> </div>

ベルマン方程式

$$\begin{aligned} V^\pi(s) &= \mathbb{E}[G_t | S_t = s] \\ &= \mathbb{E}[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s', r} P(s', r | s, a) [r + \gamma \mathbb{E}_\pi[G_{t+1} | S_{t+1} = s']] \\ &= \sum_a \pi(a|s) \sum_{s', r} P(s', r | s, a) [r + \gamma V^\pi(s')] \\ Q^\pi(s, a) &= \mathbb{E}[R_{t+1} + \gamma V^\pi(S_{t+1}) | S_t = s, A_t = a] \\ &= \sum_{s', r} P(s', r | s, a) [r + \gamma V^\pi(s')] \end{aligned}$$

各要素の意味

<div style="page-break-after: always;"> </div>

SARSA

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

各要素の意味

<div style="page-break-after: always;"> </div>

Q学習

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right]$$

各要素の意味

<div style="page-break-after: always;"> </div>

方策勾配定理

$$\nabla_{\theta} J(\theta) = \sum d^{\pi_{\theta}}(s) \sum \nabla_{\theta} \pi_{\theta}(a|s, \theta) Q^{\pi_{\theta}}(s, a)$$

$$\nabla_{\theta} \log \pi_{\theta}(a|s) = \frac{\partial \pi_{\theta}(a|s)}{\partial \theta} \frac{1}{\pi_{\theta}(a|s)}$$

$$d^{\pi_{\theta}}(s) = \sum_{k=0}^{\infty} \gamma^k P^{\pi_{\theta}}(s_k = s | s_0)$$

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \sum d^{\pi_{\theta}}(s) \sum_a (\nabla_{\theta} \pi_{\theta}(a|s, \theta)) Q^{\pi_{\theta}}(s, a) \\ &= \sum d^{\pi_{\theta}}(s) \sum_a \pi_{\theta}(a|s, \theta) (\nabla_{\theta} \log \pi_{\theta}(a|s, \theta)) Q^{\pi_{\theta}}(s, a) \\ &= \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s, \theta) Q^{\pi_{\theta}}(s, a)] \end{aligned}$$

各要素の意味

<div style="page-break-after: always;"> </div>

モンテカルロ近似

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}}[f(s, a)] \approx \frac{1}{N} \sum_{n=1}^N \frac{1}{T} \sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(a_t^n | s_t^n) Q^{\pi_{\theta}}(s_t^n, a_t^n)$$

各要素の意味

<div style="page-break-after: always;"> </div>

交差エントロピー誤差

$$E = -\frac{1}{N} \sum_n \sum_k t_{nk} \log y_{nk}$$

各要素の意味

- N : データ個数
- k : データの次元数

<div style="page-break-after: always;"> </div>

アフィンレイヤ

$$H = XW + B$$
$$\frac{\partial L}{\partial W} = X^T \frac{\partial L}{\partial H}$$

各要素の意味

<div style="page-break-after: always;"> </div>

モーメントム

$$v_{t+1} = \alpha v_t - \eta \frac{\partial L}{\partial \theta_t}$$

$$\theta_{t+1} = \theta_t + v_{t+1}$$

各要素の意味

<div style="page-break-after: always;"> </div>

確率的勾配降下法 ※1/8追加

各要素の意味

`<div style="page-break-after: always;" > </div>`

NesterovAG

$$v_{t+1} = av_t - \eta \frac{\partial L}{\partial (\theta_t + av_t)}$$
$$\theta_{t+1} = \theta_t + v_{t+1}$$

各要素の意味

<div style="page-break-after: always;"> </div>

AdaGrad

$$h_{t+1} = h_t + \frac{\partial L}{\partial \theta_t} \odot \frac{\partial L}{\partial \theta_t}$$

$$\theta_{t+1} = \theta_t - \eta \frac{1}{\varepsilon + \sqrt{h_{t+1}}} \odot \frac{\partial L}{\partial \theta_t}$$

各要素の意味

<div style="page-break-after: always;"> </div>

RMSProp

$$h_{t+1} = \rho h_t + (1 - \rho) \frac{\partial L}{\partial \theta_t} \odot \frac{\partial L}{\partial \theta_t}$$

$$\theta_{t+1} = \theta_t - \eta \frac{1}{\sqrt{\varepsilon + h_{t+1}}} \odot \frac{\partial L}{\partial \theta_t}$$

各要素の意味

<div style="page-break-after: always;"> </div>

Adam

$$m_{t+1} = \rho_1 m_t + (1 - \rho_1) \frac{\partial L}{\partial \theta_t}$$

$$v_{t+1} = \rho_2 v_t + (1 - \rho_2) \frac{\partial L}{\partial \theta_t} \odot \frac{\partial L}{\partial \theta_t}$$

$$\hat{m}_{t+1} = \frac{m_{t+1}}{1 - \rho_1^t}$$

$$\hat{v}_{t+1} = \frac{v_{t+1}}{1 - \rho_2^t}$$

$$\theta_{t+1} = \theta_t - \eta \frac{1}{\sqrt{\quad}} \odot \hat{m}_{t+1}$$

バッチ正規化

$$h' = \frac{h - \mu}{\sigma}$$
$$\gamma h' + \beta$$

各要素の意味

<div style="page-break-after: always;"> </div>

畳み込み

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) K(m, n)$$

各要素の意味

<div style="page-break-after: always;"> </div>

IoU

$$IoU(B_{true}, B_{pred}) = \frac{|B_{true} \cap B_{pred}|}{|B_{true} \cup B_{pred}|} = \frac{|B_{true} \cap B_{pred}|}{|B_{true}| + |B_{pred}| - |B_{true} \cap B_{pred}|}$$

各要素の意味

<div style="page-break-after: always;"> </div>

Dice 係数

$$Dice(S_{true}, S_{pred}) = \frac{|S_{true} \cap S_{pred}|}{\frac{|S_{true}| + |S_{pred}|}{2}} = \frac{2|S_{true} \cap S_{pred}|}{|S_{true}| + |S_{pred}|}$$

各要素の意味

<div style="page-break-after: always;"> </div>

AP

$$AP = \frac{1}{11} \sum_{r \in \{0, 0.1, 0.2, \dots, 1\}} p_{interp}(r)$$

$$p_{interp}(r) = \max_{\tilde{r} \geq r} p(\tilde{r})$$

各要素の意味

<div style="page-break-after: always;"> </div>

LSTMの順伝播

$$G = \tanh \left(X_t W_x^{(g)} + H_{t-1} W_h^{(g)} + b^{(g)} \right)$$

$$I = \text{sigmoid} \left(X_t W_x^{(i)} + H_{t-1} W_h^{(i)} + b^{(i)} \right)$$

$$F = \text{sigmoid} \left(X_t W_x^{(f)} + H_{t-1} W_h^{(f)} + b^{(f)} \right)$$

$$O = \text{sigmoid} \left(X_t W_x^{(o)} + H_{t-1} W_h^{(o)} + b^{(o)} \right)$$

各要素の意味

<div style="page-break-after: always;"> </div>

GRUの順伝播

$$R = \text{sigmoid} \left(X_t W_x^{(r)} + H_{t-1} W_h^{(r)} + b^{(r)} \right)$$

$$Z = \text{sigmoid} \left(X_t W_x^{(z)} + H_{t-1} W_h^{(z)} + b^{(z)} \right)$$

$$\tilde{H} = \tanh \left\{ X_t W_x^{(\tilde{h})} + (R \odot H_{t-1}) W_h^{(\tilde{h})} + b^{(\tilde{h})} \right\}$$

$$H_t = Z \odot H_{t-1} + (1 - Z) \odot \tilde{H}$$

各要素の意味

<div style="page-break-after: always;"> </div>

WaveNetの定式化

$$p(x) = \prod_{t=1}^T p(x_t | x_1, x_2, \dots, x_{t-1})$$

各要素の意味

<div style="page-break-after: always;"> </div>

TransformerのScaled Dot-Product Attention

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

各要素の意味

<div style="page-break-after: always;"> </div>

TransformerのPositional Encoding

$$PE(pos, 2i) = \sin \left(pos / 10000^{2i/d_{model}} \right)$$

$$PE(pos, 2i + 1) = \cos \left(pos / 10000^{2i/d_{model}} \right)$$

各要素の意味

<div style="page-break-after: always;"> </div>

VAEの損失関数

$$-\log p(x) \leq -L = \mathbb{E}_{z \sim p(z|x)} [-\log p(x|z)] + \int \log \left(\frac{p(x|z)}{p(z)} \right) p(z|x) dz$$

各要素の意味

<div style="page-break-after: always;"> </div>

GANの定式化

$$\min_G \max_D \mathbb{E}_{\mathbf{x}} [\log D(x)] + \mathbb{E}_{\mathbf{z}} [\log(1 - D(G(z)))]$$

各要素の意味

<div style="page-break-after: always;"> </div>

DQN

$$L(\theta) = \mathbb{E}_{s,a,r,s' \sim \mathbb{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right]$$

各要素の意味

<div style="page-break-after: always;"> </div>

蒸留における温度付きソフトマックス関数

$$\text{Softmax}(z)_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

各要素の意味